



Universidad del Valle de Guatemala

Facultad de Ingeniería

Ciencia de Datos (CC3084)

Laboratorio 7

Spark MLlib: segmentación y predicción del salario mensual con la ENEIC

Nicolás Concuá — 23197

Felipe Aguilar — 23195

Guatemala, 25 de septiembre de 2026

Introducción

El laboratorio responde dos preguntas con las bases de Personas de la Encuesta Nacional de Empleo e Ingresos Continua (ENEIC) del INE: qué perfiles de trabajadores asalariados pueden identificarse y qué tan bien puede estimarse su salario mensual a partir de características personales y laborales. Los cuatro trimestres de 2025 se usan para desarrollar los modelos y el primer trimestre de 2026 como prueba final. Todo el procesamiento y el modelado se hicieron con Spark 3.5.1 (pyspark.ml) en Docker; pandas solo se usó para leer los Excel y graficar agregados o muestras. El análisis es no ponderado: describe los registros elegibles y no constituye una estimación oficial para la población del país.

Repositorio: <https://github.com/FelipeAP04/Lab7-DataScience>

1. Carga, armonización y calidad de datos

Cada Excel se leyó por separado (solo las 14 columnas necesarias), se convirtió a Spark con esquema explícito y se le agregaron `periodo_archivo`, `anio_archivo`, `trimestre_calendario` y `archivo_origen` según el archivo de procedencia, sin restar uno a TRIMESTRE. Los cuatro trimestres de 2025 se unieron con `unionByName`: el archivo IV de 2025 tiene 302 columnas frente a 270 de los demás, así que apilarlo por posición desplazaría variables y mezclaría significados.

Antes de filtrar, OCUPADOS, antigüedad, horas y P05C16 faltan en el 56.7 % de los registros de 2025, el nivel educativo en el 12.9 % y el salario en el 74.0 %. La mayoría de esos vacíos son preguntas que **no aplican** por el flujo del cuestionario (por ejemplo, no se pregunta el salario a quien no trabaja), lo cual es distinto de una respuesta que sí correspondía pero **no fue registrada**. La clave `periodo_archivo` + `NUM_HOGAR` + `NUM_PERSONA` no presentó duplicados en ningún conjunto. Una misma persona puede aparecer en varios trimestres por el diseño longitudinal con rotación; esas son observaciones válidas de periodos distintos y no deben eliminarse como duplicados.

Tabla 1. Registros excluidos por paso (de 203,676 registros en 2025 y 49,843 en 2026T1).

Paso de filtrado (mismo orden en ambos conjuntos)	Excluidos 2025	Excluidos 2026T1
Edad finita y ≥ 15	62,886	14,803
Persona ocupada (OCUPADOS = 1)	52,568	13,306
Asalariada (P05C16 en 1–4)	35,197	8,476
Salario, antigüedad, meses, antigüedad $\leq$ edad y horas 1–168	0	0
Registros finales	53,025	13,258

Por trimestre quedaron 13,419 (2025T1), 13,492 (2025T2), 13,450 (2025T3), 12,664 (2025T4) y 13,258 (2026T1) registros. Los códigos se normalizaron como texto y se validaron contra el diccionario; los ausentes o no reconocidos se marcan como DESCONOCIDO y el código educativo 0 se conserva como NINGUNO. La base filtrada no representa a todos los trabajadores del país: excluye a independientes, familiares no remunerados y asalariados sin salario registrado, y además no usa el factor de expansión. FACTOR se conserva porque sería necesario para producir estimaciones poblacionales. Los conjuntos de 2025 y 2026T1 se guardaron por separado en Parquet.

2. Estadística descriptiva de 2025

Tabla 2. Estadísticos de 2025 (n = 53,025 en todas las variables).

Variable	Media	Mediana	Desv. est.	Mín.	P25	P75	P95	Máx.
Salario (Q)	3,421.7	3,000	2,902.1	1	1,800	4,000	8,000	99,000
Edad	35.2	33	13.5	15	24	44	61	89
Antigüedad	5.6	2.0	7.8	0	0.5	7	22	70
Horas	46.3	45	18.6	1	40	55	80	126




Figura 1. Distribución del salario mensual en escala original y en escala logarítmica base 10 (muestra de 10,000).

El salario tiene una fuerte **asimetría positiva**: la media (Q3,422) supera a la mediana (Q3,000) en unos Q420 por la cola de salarios altos, que llega a Q99,000. En escala logarítmica la distribución se vuelve aproximadamente simétrica. Por categoría, la empresa privada concentra 28,702 registros, seguida de jornaleros (13,842), gobierno (6,575) y servicio doméstico (3,906). Los niveles educativos más frecuentes son diversificado (16,851) y primaria (15,822), y el dominio urbano metropolitano es el de mayor peso.




Figura 2. Salario mediano por nivel educativo, categoría ocupacional y trimestre de 2025.

El salario mediano crece con la escolaridad: pasa de Q1,500 sin estudios a Q2,200 en primaria, Q3,600 en diversificado, Q5,000 en educación superior y Q10,000–Q12,000 en posgrado (estos últimos con pocas observaciones). Por categoría va de Q1,000 en servicio doméstico a Q5,000 en empleo público. Entre trimestres, la muestra analítica baja de 13,492 registros en 2025T2 a 12,664 en 2025T4, mientras la mediana sube de Q3,000 a Q3,200.

3. Relaciones entre variables numéricas

Con VectorAssembler y Correlation.corr() sobre los 53,025 registros, la antigüedad es la variable con mayor asociación lineal con el salario ($r = 0.180$), seguida de edad ($r = 0.147$) y horas semanales ($r = 0.076$); todas son débiles. Edad y antigüedad tienen una relación moderada ($r = 0.487$), coherente con el tiempo necesario para acumular antigüedad. Las horas se relacionan levemente de forma negativa con la edad ($r = -0.105$).

4. Segmentación de perfiles con KMeans

Se estandarizaron edad, antigüedad y horas semanales (StandardScaler con media y desviación) y se compararon $K = 2, 3, 4$ y 5 con el coeficiente de silueta, en dos especificaciones: con y sin salario. Sin salario se obtiene la mejor silueta (0.554 con $K = 2$, frente a 0.512 al incluir el salario). Además, incluirlo haría que la cola salarial dominara las distancias. Por eso el salario se reservó para describir los grupos.




Figura 3. Matriz de correlaciones de Pearson (izquierda) y silueta por K (derecha).

- **Clúster 0, trabajadores mayores y estables (27.7 %):** edad media de 51.3 años, 13.8 años de antigüedad, 41.3 horas semanales y salario mediano de Q3,450.
- **Clúster 1, jóvenes con poca antigüedad y jornada extensa (72.3 %):** edad media de 29.0 años, 2.4 años de antigüedad, 48.2 horas y salario mediano de Q3,000.

Los clústeres son perfiles descriptivos de similitud y no clases naturales; dependen de las variables elegidas, de la estandarización y de K .

5. Pipeline de regresión lineal

Se estimó salario_mensual con exactamente seis predictores: edad, antigüedad, horas semanales, nivel educativo, categoría ocupacional y dominio. Se entrenó con 2025T1–T3 (40,361 registros) y se validó con 2025T4 (12,664). El pipeline encadena StringIndexer (handleInvalid = keep) y OneHotEncoder para las categóricas, VectorAssembler, StandardScaler y LinearRegression; todas las etapas se ajustan solo con el entrenamiento. El modelo de referencia predice la media de entrenamiento (Q3,383).

De las seis configuraciones de la Tabla 3 se eligió la regresión **sin penalización** por tener el menor RMSE, aunque las seis configuraciones prácticamente empatan: con unos 40 mil registros y pocas variables no hay sobreajuste que corregir. Frente a la referencia, el RMSE baja unos Q700 y el R^2 sube a 0.426. Los coeficientes estandarizados más grandes corresponden a maestría (+Q830), educación superior (+Q592) y empleo de gobierno (+Q467), y los más negativos a servicio doméstico (−Q367), primaria y ninguna escolaridad.

Tabla 3. Configuraciones de regresión lineal en validación (2025T4). Referencia: RMSE = Q2,889.6, $R^2 \approx 0$.

regParam	elasticNetParam	Tipo	MAE (Q)	RMSE (Q)	R ²
0	0	Sin penalización	1,210.1	2,186.4	0.426
10	0	Ridge	1,209.7	2,186.6	0.426
10	1	Lasso	1,206.2	2,187.3	0.425
100	0	Ridge	1,205.9	2,188.1	0.425
50	0.5	Elastic Net	1,200.5	2,190.1	0.424
100	1	Lasso	1,198.0	2,213.1	0.412

6. Pipeline de Random Forest

Con las mismas etapas de codificación, los mismos conjuntos y semilla 42, se variaron el número de árboles y la profundidad máxima (sin estandarización, que los árboles no necesitan).

En la Tabla 4, la profundidad importa mucho más que el número de árboles. Se eligieron **100 árboles con profundidad 20**; de 15 a 20 la mejora ya es marginal (Q9 de RMSE). En validación, Random Forest supera a la regresión lineal por unos Q210 de RMSE, Q160 de MAE y 11 puntos de R^2 . La diferencia se explica porque los árboles capturan **interacciones y no linealidades** (el efecto de la educación depende de la categoría ocupacional y del dominio), mientras la regresión lineal supone efectos aditivos. Según las importancias, maestría, educación superior, horas, edad y empleo de gobierno concentran la mayor parte de la información.

Tabla 4. Configuraciones de Random Forest en validación (2025T4).

numTrees	maxDepth	MAE (Q)	RMSE (Q)	R ²
100	20	1,051.8	1,972.4	0.533
100	15	1,059.2	1,981.2	0.528
50	10	1,081.8	2,016.9	0.511
100	10	1,081.4	2,021.7	0.509
100	5	1,159.8	2,161.9	0.438
50	5	1,165.6	2,164.2	0.437

7. Entrenamiento final y evaluación en 2026T1

Cada pipeline se reentrenó con los cuatro trimestres de 2025 usando la configuración elegida y se evaluó sobre los mismos 13,258 registros elegibles de 2026T1, preparados con las mismas reglas.

Tabla 5. Evaluación final en 2026T1 ($n = 13,258$).

Modelo	MAE (Q)	RMSE (Q)	R ²
Referencia (media de 2025)	1,718.1	2,871.4	-0.003
Regresión lineal	1,240.7	2,163.8	0.431
Random Forest	1,079.5	1,937.8	0.543

El orden de validación se mantiene y las métricas de prueba son incluso un poco mejores, así que no hay señal de sobreajuste y la relación entre las variables y el salario fue estable entre 2025 y 2026T1. Aun así, el MAE del mejor modelo equivale a cerca de un tercio del salario mediano de prueba (Q3,200).

8. Visualización y análisis de errores

El residuo se define como $\text{real} - \text{predicho}$: positivo indica subestimación y negativo, sobreestimación. Los gráficos usan la misma muestra de 5,000 registros para ambos modelos; las tablas usan todo el conjunto de prueba.




Figura 4. Salario real frente a predicho (con $y = x$) y residuos frente a predicho. Escala symlog, valores en quetzales.

Las nubes siguen la recta $y = x$, pero con gran dispersión. Las franjas horizontales corresponden a salarios reportados en montos redondos. Los residuos se abren conforme crece la predicción (heterocedasticidad) y, en salarios reales altos, la mayoría de los puntos queda por encima de la recta.

En la Tabla 6, el MAE crece con el nivel educativo y en el área metropolitana porque ahí los salarios son más altos y dispersos. El error medio es positivo en casi todos los grupos: hay una leve subestimación general, muy fuerte en doctorado (solo 12 casos).

Tabla 6. MAE y error medio (Q) por nivel educativo (selección) y por dominio en 2026T1.

Grupo	n	MAE lineal	Error medio lineal	MAE RF	Error medio RF
Primaria	3,957	870	+55	741	+55
Diversificado	4,117	1,109	+104	996	+102
Superior	1,729	2,566	+296	2,252	+246
Maestría	183	5,553	-132	4,737	-332
Doctorado	12	12,919	+6,063	11,870	+7,469
Urbano metropolitano	5,632	1,446	+136	1,302	+142
Resto urbano	4,846	1,190	+134	1,011	+102
Rural nacional	2,780	914	+65	748	+47




Figura 5. Error medio por tramo de percentil del salario real en 2026T1 (escala symlog).

Los percentiles del salario de prueba son P25 = Q2,000, P50 = Q3,200, P75 = Q4,080, P90 = Q6,000, P95 = Q8,000 y P99 = Q15,000. Los errores muestran una clara **regresión hacia la media**: por debajo de P25 ambos modelos sobreestiman (-Q829 la lineal y -Q710 Random Forest); entre P25 y P75 el sesgo es pequeño; y a partir de P75 **subestiman** de forma creciente: +Q446 a +Q493 en P75-P90, +Q1,420 a +Q1,634 en P90-P95, +Q3,368 a +Q4,092 en P95-P99 y más de +Q12,000 en el 1 % superior. Las seis variables no distinguen salarios extremos dentro de un mismo perfil y la pérdida cuadrática empuja las predicciones hacia la media condicional; Random Forest reduce ese sesgo, pero no lo elimina. Como los salarios altos se conservaron, el RMSE es ≈ 1.8 veces el MAE.

Discusión final

- El salario es muy asimétrico y se explica mejor por educación y categoría ocupacional que por variables numéricas, cuyas correlaciones con el salario son débiles. KMeans separa a trabajadores mayores y estables de jóvenes con poca antigüedad y jornadas largas.
- Random Forest (100 árboles, profundidad 20) fue el mejor modelo en validación y en prueba ($R^2 = 0.543$, RMSE = Q1,938), por encima de la regresión lineal ($R^2 = 0.431$) y muy por encima de la referencia. La regularización no aportó mejoras.
- Ambos modelos sobreestiman los salarios bajos y subestiman sistemáticamente los altos. Faltan variables clave, como ocupación, rama de actividad, tamaño de empresa o formalidad, para explicar el resto de la variabilidad: los modelos describen patrones promedio, no salarios individuales, y sus asociaciones no son causales.